

Procesamiento de Imágenes

Docente: Charletti, Carlos

EQUIPO: NucleoTech Soluciones

GITHUB:

<https://github.com/NucleoTech-Soluciones/Monitoreo-de-Gallinas-Ponedoras>

Integrantes:

Nombre y Apellido	DNI	Usuario GitHub
Andrada, Florencia	44.788.525	Flor3ncia-Andr4d4
Córdoba, Federico	29.208.191	Fede-cordoba-ispc
Juncos, David	29.686.787	davidJuncos
Mendoza Despontin, Guadalupe	45964026	Guadamendoza
Pereyra, Hebe	33.117.717	PereyraHebe
Soto, Noelia	41.253.579	NoeliaSoto
Suarez, Mariela	21.718.397	MarielarosaSZ

Proyecto ABP: Monitoreo de Gallinas Ponedoras

NOMBRE DEL PROYECTO

"Sistema de Visión Artificial para la Detección de Gallinas en Imágenes Aéreas".

TIPO DE PROYECTO

Tecnológico.

ESPACIO CURRICULAR

Procesamiento de Imágenes - TSCDIA - 2024.

EJES TEMÁTICOS

Visión por computadora, técnicas de preprocesamiento de imágenes digitales con **OpenCV**, **Python**, **Keras** **CV**, y redes neuronales convolucionales para detección de objetos utilizando el modelo YOLOv8. Se abordarán conceptos de limpieza de imagen (mitigación de sombras), armado y etiquetado de un *dataset* personalizado, y validación de resultados observables.

PROBLEMÁTICA

¿Cómo puede un gallinero gestionar y monitorear de forma confiable a sus aves en condiciones reales de pastoreo?

En un escenario con cambios de iluminación y presencia de múltiples elementos similares en el terreno, resulta necesario identificar con precisión la ubicación y presencia de gallinas para apoyar decisiones de manejo. Sin embargo, el reconocimiento en imágenes capturadas desde un dron se vuelve difícil porque la escena varía con la luz y además aparecen objetos que pueden confundirse con las aves. Por ello, el proyecto debe resolver el problema desarrollando un modelo base capaz de distinguir automáticamente gallinas del resto de elementos del terreno a partir de imágenes obtenidas por dron.

FUNDAMENTACIÓN

Elegimos este proyecto frente a otras opciones tecnológicas porque el monitoreo manual de aves de corral en entornos de pastoreo libre es una tarea exhaustiva, costosa y que consume mucho tiempo para los productores. Identificar animales en el campo es un desafío complejo debido a factores ambientales como la iluminación, las sombras y la oclusión generada por la vegetación y la extensión del territorio. Decidimos abordar este problema específico porque la visión artificial nos permite automatizar esta labor, superando estas barreras visuales de manera eficiente.

El potencial de este proyecto radica en sentar las bases para un sistema de monitoreo agrícola escalable, continuo y de bajo costo. Al lograr entrenar un modelo que detecte con éxito a las gallinas en imágenes estáticas, se habilita la futura integración de este sistema en una aplicación móvil o de borde (*Edge Computing*). Esto abrirá la puerta a sistemas más avanzados que automaticen por completo la gestión del gallinero inteligente sin requerir hardware costoso en la nube.

A nivel productivo, este desarrollo impacta directamente en el sector agropecuario al proponer una herramienta que optimiza el tiempo de los trabajadores rurales y reduce drásticamente la carga laboral, compensando la falta de mano de obra en el campo. Además, tiene un impacto altamente positivo en el **bienestar animal**; el uso de la visión artificial combinada con drones permite un monitoreo no invasivo a distancia que reduce la presencia humana constante y, por ende, minimiza el estrés en las aves.

Como futuros profesionales de la Ciencia de Datos nos permite aplicar de forma práctica y progresiva las herramientas claves de la materia en un escenario del mundo real y nos exige dominar el preprocesamiento de imágenes utilizando librerías como OpenCV para limpiar las capturas y eliminar sombras, y al mismo tiempo, nos introduce en el entrenamiento de redes neuronales convolucionales de vanguardia, como YOLOv8, que son el estándar actual en la industria para la detección de objetos.

VISIÓN DEL PROYECTO

Desarrollar un modelo de inteligencia artificial funcional y documentado que analice fotografías aéreas, detecte a las gallinas presentes en la imagen y las encierre en cuadros delimitadores (*bounding boxes*), demostrando la viabilidad de la visión artificial en el campo.

OBJETIVO GENERAL

Entrenar un modelo de aprendizaje automático, utilizando técnicas previas de procesamiento de imágenes, que sea capaz de detectar y clasificar gallinas en fotografías aéreas de entornos de pastoreo.

OBJETIVOS ESPECÍFICOS

- **Construir un dataset de imágenes** de gallinas en tomas aéreas y realizar el etiquetado manual dibujando los cuadros delimitadores alrededor de cada ave para el entrenamiento.
- **Aplicar algoritmos de preprocesamiento (OpenCV)** para limpiar las imágenes, por ejemplo, utilizando umbralización o filtros para reducir el impacto de las sombras antes de pasarlas por la red neuronal.

- **Entrenar el modelo YOLOv8** para que aprenda a identificar la clase específica "gallina", evaluando durante el proceso la reducción del margen de error .
- **Validar los resultados observables** pasando imágenes nuevas por el modelo y organizar el código, los *notebooks* de experimentación y la documentación en un repositorio de **GitHub**.

SELECCIÓN PRELIMINAR DEL DATASET

Para el desarrollo de este proyecto se realizó una búsqueda de datasets públicos de imágenes aéreas de aves de corral. Como selección preliminar se optará por un dataset obtenido desde la plataforma Roboflow, que reúne imágenes capturadas desde perspectiva aérea en entornos de pastoreo real, con anotaciones en formato compatible con YOLOv8.

https://drive.google.com/file/d/1pyQERTpJGcQwFTh7apRXLVHZxC5-ghVZ/view?usp=drive_link

Además adjuntamos una carpeta de imágenes para su rápida evaluación:

https://drive.google.com/drive/folders/1uBzuHNeEIKOffCLBC8oSBIGBUONdLPFM?usp=drive_link

Los criterios que guiaron esta selección fueron: la perspectiva aérea de las capturas (condición indispensable para representar el uso de drones), la presencia de variaciones de iluminación y sombras que reproducen el desafío visual planteado en la problemática, y la disponibilidad de anotaciones ya etiquetadas en formato bounding box que permiten iniciar el entrenamiento sin requerir un etiquetado manual completo desde cero.

El dataset será analizado, preprocesado y documentado en el repositorio del equipo en GitHub a medida que avance el proyecto

*ACLARACIÓN DEL ALCANCE Y FUTURAS ETAPAS

Debido a las limitaciones temporales inherentes al espacio curricular Procesamiento de Imágenes y con el objetivo de garantizar la finalización exitosa de la etapa fundamental, se ha decidido acotar el alcance inicial del proyecto.

El objetivo a largo plazo del proyecto original "Monitoreo de Gallinas Ponedoras" es implementar un sistema completo de monitoreo y conteo en tiempo real, lo que implica el uso de algoritmos de rastreo (tracking) sobre secuencias de video (por ejemplo, DeepSORT). Sin embargo, esta funcionalidad de monitoreo en tiempo real se abordará en una Segunda Etapa.

La presente etapa se enfoca exclusivamente en la Detección de Gallinas en Imágenes Aéreas Estáticas, sirviendo como el cimiento tecnológico necesario para la posterior implementación del monitoreo temporal.

Sección "Segunda Evidencia"

Título: Segunda Evidencia - Implementación de Redes Neuronales Convolucionales (CNN)

Link a colab: [🔗 Evidencia2_ Procesamiento_imagenes - Clasificación.ipynb](#)

En esta etapa del proyecto, avanzamos en la creación y el entrenamiento de un modelo de visión artificial diseñado para la clasificación binaria de imágenes, con el fin de distinguir el contenido en dos posibles estados: "Gallina: Sí" o "Gallina: NO".

El objetivo principal de esta fase fue validar la capacidad de una red neuronal para identificar la presencia de aves de corral en capturas aéreas. Si bien el objetivo final de nuestro proyecto apunta a la utilización de la arquitectura YOLOv8 para la detección y el seguimiento de objetos, se tomó la decisión estratégica de comenzar con una clasificación binaria.

Dado que en esta instancia no contábamos aún con el conocimiento avanzado necesario para implementar YOLO, esta etapa funcionó como un espacio fundamental de investigación de posibles modelos y de aprendizaje académico, permitiéndonos consolidar las bases teóricas y el manejo de datos antes de avanzar hacia herramientas más complejas.

Para que este aprendizaje fuera efectivo, el primer desafío consistió en el tratamiento del conjunto de datos (*dataset*). Tuvimos que trabajar exhaustivamente sobre los archivos y la estructura de carpetas, completar la definición de una clase y aplicar técnicas de balanceo de datos y finalmente dividir los datos de entrenamiento y los de prueba. Este paso fue crucial para asegurar que la red neuronal tuviera la misma proporción de ejemplos positivos y negativos, evitando que el modelo desarrollara sesgos durante su entrenamiento.

Una vez preparados los datos, se procedió a la etapa de carga y preprocesamiento. Para ello, se implementó una canalización de datos (pipeline) utilizando la librería TensorFlow, la cual nos permitió leer y cargar las fotografías directamente desde un repositorio en Google Drive.

Todas las imágenes aéreas fueron redimensionadas a una resolución estándar de 128 x 128 píxeles. Adicionalmente, se aplicó una normalización para llevar los valores de los píxeles

(originalmente de 0 a 255) a un rango de 0 a 1, un paso indispensable para que la red neuronal procese la información numérica de manera más rápida, optimizando el costo computacional.

En cuanto a la arquitectura del modelo, se diseñó una Red Neuronal Convolucional (CNN) estructurada específicamente para nuestra tarea.

La red está compuesta por tres capas de convolución (Conv2D) encargadas de la extracción de características visuales clave en las imágenes. Estas son seguidas por capas de Max-Pooling, las cuales fueron utilizadas para la reducción de la dimensionalidad, conservando únicamente la información más relevante.

Para garantizar que el modelo aprenda patrones generales y no se limite a memorizar las fotografías de entrenamiento, se introdujo una capa estratégica de Dropout configurada al 0.5, lo cual previene eficazmente el problema del sobreajuste (*overfitting*).

Finalmente, la arquitectura culmina en una capa de salida con una función de activación Sigmoide, la cual es matemáticamente ideal para la clasificación binaria.

El proceso de entrenamiento se ejecutó a lo largo de 10 épocas, utilizando el optimizador Adam por su gran eficiencia en el ajuste de los pesos de la red, y la función de pérdida *binary_crossentropy* para evaluar el margen de error.

Los resultados obtenidos fueron sumamente satisfactorios: el modelo logró alcanzar una precisión de validación cercana al 97%, demostrando una excelente capacidad de generalización frente a los datos.

Finalmente, para corroborar la robustez del sistema, se llevó a cabo una fase de validación externa. Se realizaron pruebas utilizando imágenes de control y muestras externas procesadas mediante la librería Skimage. En estas pruebas, se expuso intencionalmente al modelo a objetos no relacionados y a otros animales, como gatos, para verificar su comportamiento frente a posibles falsos positivos. El sistema logró discriminar correctamente estos elementos externos, confirmando que realmente ha aprendido a identificar las características propias de las gallinas.